TD2: Statistique descriptive & Probabilité
IHEC Sousse, Université de Sousse
L1-DSBA

2026/2027

Equipe pédagogique : Hamrita, M.E ; Dorbez, M ; Idoudi, O

Objectifs

Cette feuille porte sur les paramètres de position (moyenne, médiane, mode, quantiles), l'asymétrie et l'aplatissement d'une distribution statistique.

Exercices théoriques

Exercice 1

On observe les notes suivantes (sur 20) :

$$8,\ 10,\ 10,\ 11,\ 12,\ 12,\ 12,\ 15,\ 18.$$

a) Calculer la moyenne, la médiane et le mode.

b) On remplace la note 18 par 38. Calculer la nouvelle moyenne et expliquer pourquoi la médiane change peu ou pas.

c) Quel paramètre de position conseilleriez-vous pour résumer les notes en présence d'une valeur extrême ? Justifier.

Exercice 2

Les temps d'attente (en minutes), rangés par ordre croissant, sont :

$$4,\ 5,\ 6,\ 6,\ 7,\ 8,\ 9,\ 10,\ 12,\ 15,\ 18,\ 22.$$

a) Déterminer la médiane.

b) En adoptant la convention des rangs les plus proches $Q_1 = x_{(\lceil n/4 \rceil)}$ et $Q_3 = x_{(\lceil 3n/4 \rceil)}$, calculer Q_1 et Q_3.

c) Calculer l'écart interquartile $IQR = Q_3 - Q_1$ et interpréter sa signification.

d) Déterminer les bornes de Tukey $Q_1 - 1{,}5IQR$ et $Q_3 + 1{,}5IQR$. Y a-t-il une valeur atypique selon cette règle ?

Exercice 3

Deux groupes d'étudiants obtiennent les résultats suivants :

$$A = (9, 10, 10, 11, 12, 12, 13), \qquad B = (4, 8, 10, 11, 12, 15, 17).$$

a) Calculer la moyenne et la médiane de chaque groupe.

b) Comparer les deux groupes en termes de position.

c) Sans calculer tous les moments, expliquer quel groupe semble le plus dispersé et pourquoi les paramètres de position ne suffisent pas à comparer complètement les distributions.

Exercice 4

On considère trois distributions dont les coefficients d'asymétrie sont respectivement $g_1 = -0{,}85$, $g_1 = 0{,}03$ et $g_1 = 1{,}20$.

a) Qualifier l'asymétrie de chaque distribution.

b) Pour chacune, indiquer de quel côté se trouve généralement la queue la plus longue.

c) Dans quelles conditions la relation moyenne–médiane peut-elle aider à repérer l'asymétrie ? Pourquoi ne s'agit-il pas d'une règle absolue ?

Exercice 5

Pour trois séries, on obtient les excès d'aplatissement suivants :

$$\gamma_2^{(A)} = 1{,}6, \qquad \gamma_2^{(B)} = -0{,}7, \qquad \gamma_2^{(C)} = 0{,}05.$$

a) Classer les distributions selon leur excès d'aplatissement.

b) Qualifier chacune de leptokurtique, platykurtique ou proche de la référence normale.

c) Expliquer pourquoi un excès positif ne signifie pas simplement que la distribution est « plus pointue », et pourquoi les valeurs extrêmes peuvent fortement influencer ce coefficient.

d) Distinguer le coefficient d'aplatissement $\beta_2 = m_4/m_2^2$ de l'excès $\gamma_2 = \beta_2 - 3$.

Corrigés des exercices théoriques

Corrigé 1

La somme des neuf notes vaut

$$8 + 10 + 10 + 11 + 12 + 12 + 12 + 15 + 18 = 108,$$

donc $\bar{x} = 108/9 = 12$. La série contient neuf valeurs ordonnées ; la cinquième est la médiane, soit $Me = 12$. La valeur 12 apparaît trois fois, davantage que toute autre valeur : le mode est $Mo = 12$.

Après remplacement de 18 par 38, la somme augmente de 20 et devient 128. La nouvelle moyenne est $128/9 \simeq 14{,}22$. La série ordonnée devient $8, 10, 10, 11, 12, 12, 12, 15, 38$ la médiane reste 12. La moyenne est sensible à une valeur extrême, contrairement à la médiane qui dépend essentiellement du rang des observations. En présence d'une valeur extrême, la médiane est donc souvent un résumé robuste de la position centrale ; la moyenne reste utile lorsque l'on veut tenir compte de toutes les valeurs et que les valeurs extrêmes sont pertinentes.

Corrigé 2

Il y a $n = 12$ observations. La médiane est la moyenne des 6e et 7e valeurs :

$$Me = \frac{8 + 9}{2} = 8{,}5.$$

Avec la convention demandée,

$$Q_1 = x_{(\lceil 12/4 \rceil)} = x_{(3)} = 6, \qquad Q_3 = x_{(\lceil 36/4 \rceil)} = x_{(9)} = 12.$$

Ainsi, $IQR = 12 - 6 = 6$ minutes : la moitié centrale des observations est résumée par l'intervalle interquartile allant de 6 à 12 minutes, selon cette convention de calcul. Les bornes de Tukey sont

$$6 - 1{,}5(6) = -3, \qquad 12 + 1{,}5(6) = 21.$$

La valeur 22 dépasse la borne supérieure de 21 ; elle est donc signalée comme valeur potentiellement atypique par la règle de Tukey. Cette règle est un outil de repérage, pas une preuve qu'une observation est erronée.

Corrigé 3

Pour A, la somme est 77, donc $\bar{x}_A = 77/7 = 11$; la médiane est la quatrième valeur, $Me_A = 11$. Pour B, la somme est également 77, donc $\bar{x}_B = 11$; la médiane est aussi la quatrième valeur, $Me_B = 11$.

Les deux groupes ont la même moyenne et la même médiane. Pourtant, les valeurs de A sont regroupées autour de 11, tandis que celles de B s'étendent de 4

à 17. Le groupe B semble donc plus dispersé. La position centrale ne décrit pas à elle seule l'étalement, l'asymétrie ni la présence de valeurs extrêmes ; il faut la compléter par des mesures de dispersion et de forme.

Corrigé 4

- $g_1 = -0{,}85$: asymétrie négative, avec généralement une queue plus longue à gauche.
- $g_1 = 0{,}03$: asymétrie très faible ; la distribution est approximativement symétrique selon cet indicateur.
- $g_1 = 1{,}20$: asymétrie positive, avec généralement une queue plus longue à droite.

Dans une distribution unimodale modérément asymétrique, une asymétrie à droite est souvent associée à $\bar{x} > Me$, et une asymétrie à gauche à $\bar{x} < Me$. Cependant, cette relation n'est pas une identité mathématique générale : elle peut échouer pour des distributions multimodales, des formes irrégulières ou certains échantillons. Le coefficient de moment g_1 et l'examen graphique donnent une information complémentaire.

Corrigé 5

Les excès se classent de la manière suivante : A (1,6), C (0,05), puis B ($-0{,}7$). La série A est leptokurtique au sens du quatrième moment, la série B est platykurtique et la série C est proche de la référence normale selon cet indicateur. L'excès mesure la contribution des écarts importants à la moyenne via la puissance quatre. Il ne décrit donc pas uniquement la hauteur du sommet : les queues et les valeurs extrêmes peuvent fortement affecter le résultat. Enfin, $\beta_2 = m_4/m_2^2$ vaut 3 pour une loi normale, tandis que l'excès est $g_2 = \beta_2 - 3$ et vaut donc zéro pour cette référence.

Travaux pratiques sous R

Exercice pratique 1

On étudie les notes suivantes :

$$x = (8, 10, 10, 11, 12, 12, 12, 15, 18).$$

a) Saisir les données sous R et calculer la moyenne, la médiane, les quartiles et l'étendue.

b) Identifier le mode sans utiliser de fonction externe.

c) Ajouter une valeur extrême égale à 38 et comparer les statistiques avant et après.

Corrigé R

```r
x <- c(8, 10, 10, 11, 12, 12, 12, 15, 18)

mean(x)
median(x)
quantile(x) # R utilise par defaut type = 7
diff(range(x)) # etendue

# Mode(s) : valeur(s) avec la frequence maximale
tab <- table(x)
as.numeric(names(tab)[tab == max(tab)])

x_extreme <- c(x, 38)
mean(x_extreme)
median(x_extreme)
quantile(x_extreme)
```

Interprétation attendue. La moyenne initiale vaut 12 et la médiane vaut 12. Après ajout de 38, la moyenne augmente nettement, tandis que la médiane augmente beaucoup moins. Attention : la fonction `quantile()` de R utilise par défaut la méthode `type = 7` ; ses quartiles peuvent donc différer de ceux calculés avec une convention de rangs entiers imposée dans un exercice.

Exercice pratique 2

On considère les trois séries :

$$A = (2, 3, 3, 4, 4, 4, 5, 5, 6), \quad B = (1, 2, 3, 4, 5, 6, 7, 8, 9), \quad C = (1, 1, 2, 2, 3, 4, 5, 8, 15).$$

a) Calculer les coefficients empiriques γ_1 et γ_2 à l'aide des formules des moments.

b) Comparer les formes des trois séries.

Corrigé R

```r
A <- c(2, 3, 3, 4, 4, 4, 5, 5, 6)
B <- 1:9
C <- c(1, 1, 2, 2, 3, 4, 5, 8, 15)

moments_forme <- function(x) {
  m <- mean(x)
  m2 <- mean((x - m)^2)
  m3 <- mean((x - m)^3)
  m4 <- mean((x - m)^4)
  c(moyenne = m,
    asymetrie_g1 = m3 / m2^(3/2),
    beta2 = m4 / m2^2,
    exces_g2 = m4 / m2^2 - 3)
}

rbind(A = moments_forme(A),
      B = moments_forme(B),
      C = moments_forme(C))
```

Exercice pratique 3

Un enseignant souhaite comparer les notes de deux groupes :

```r
groupe1 <- c(9, 10, 10, 11, 12, 12, 13)
groupe2 <- c(4, 8, 10, 11, 12, 15, 17)
```

a) Calculer les paramètres de position et les coefficients g_1 et g_2.

b) Produire une boîte à moustaches commune aux deux groupes.

c) Rédiger une courte conclusion comparant leur position centrale et leur forme.

Corrigé R

```r
groupe1 <- c(9, 10, 10, 11, 12, 12, 13)
groupe2 <- c(4, 8, 10, 11, 12, 15, 17)

resume <- function(x) {
  m <- mean(x)
  m2 <- mean((x - m)^2)
  m3 <- mean((x - m)^3)
  m4 <- mean((x - m)^4)
  c(moyenne = m,
    mediane = median(x),
    Q1 = unname(quantile(x, 0.25)),
    Q3 = unname(quantile(x, 0.75)),
    asymetrie = m3 / m2^(3/2),
    exces_aplatissement = m4 / m2^2 - 3)
}

rbind(Groupe1 = resume(groupe1),
      Groupe2 = resume(groupe2))

notes <- data.frame(
  note = c(groupe1, groupe2),
  groupe = factor(rep(c("Groupe 1", "Groupe 2"),
                      c(length(groupe1), length(groupe2))))
)

boxplot(note ~ groupe, data = notes,
        col = c("lightblue", "wheat"),
        main = "Comparaison des notes",
        xlab = "Groupe", ylab = "Note")
```

Interprétation attendue. Les deux groupes ont une moyenne et une médiane égales à 11. Le groupe 2 présente toutefois un étalement plus grand, visible dans la boîte à moustaches. Les coefficients de forme permettent de compléter le diagnostic, mais doivent être interprétés avec prudence lorsque les effectifs sont faibles : avec seulement sept observations par groupe, ils peuvent être très sensibles à une seule note.