Cours de Statistiques Descriptives et Probabilité

Chapitre 2: Distribution bivariées

Mohamed Essaied Hamrita

IHEC Sousse

2026–2027

Plan du chapitre

1. Objectifs et présentation des données
2. Indépendance et test du Khi-2
3. Covariance et corrélation
4. Régression linéaire

Objectifs du chapitre

Objectif général

Introduire des outils pour étudier les relations entre deux variables statistiques X et Y définies sur une même population.

Question centrale : décider si X et Y sont suffisamment liées pour pouvoir « expliquer » raisonnablement l'une grâce à l'autre, ou au contraire si elles sont indépendantes.

Mots-clés

- Indépendance
- Distance du χ^2
- Test du χ^2 d'indépendance
- Covariance, corrélation, Régression linéaire

Notations et données

(X, Y) : couple de variables statistiques définies sur la même population P.

- N : effectif total de la population
- $n_{i,j}$: effectif du couple de modalités (x_i, y_j)
- $f_{i,j} = \dfrac{n_{i,j}}{N}$: fréquence de (x_i, y_j)

Tableau de contingence

$Y \backslash X$	y_1	y_2	$\cdots$	y_r	
x_1	$n_{1,1}$	$n_{1,2}$	$\cdots$	$n_{1,r}$	$n_{1,\cdot}$
x_2	$n_{2,1}$	$n_{2,2}$	$\cdots$	$n_{2,r}$	$n_{2,\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
x_l	$n_{l,1}$	$n_{l,2}$	$\cdots$	$n_{l,r}$	$n_{l,\cdot}$
	$n_{\cdot,1}$	$n_{\cdot,2}$		$n_{\cdot,r}$	N

Effectifs et fréquences marginales

Définition

Effectifs marginaux : $n_{i,\cdot} = \sum_{j=1}^{r} n_{i,j}, \qquad n_{\cdot,j} = \sum_{i=1}^{l} n_{i,j}$

Fréquences marginales : $f_{i,\cdot} = \frac{n_{i,\cdot}}{N}, \qquad f_{\cdot,j} = \frac{n_{\cdot,j}}{N}$

$Y \backslash X$	y_1	y_2	$\cdots$	y_r	$n_{i,\cdot}$
x_1	$n_{1,1}$	$n_{1,2}$	$\cdots$	$n_{1,r}$	$n_{1,\cdot}$
x_i	$n_{i,1}$	$n_{i,2}$	$\cdots$	$n_{i,r}$	$n_{i,\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
$n_{\cdot,j}$	$n_{\cdot,1}$	$n_{\cdot,2}$	$\cdots$	$n_{\cdot,r}$	N

Distribution conditionnelle

Définition

La distribution des observations suivant les modalités de la variable Y sachant que la variable X prend la modalité x_i, est appelée **distribution conditionnelle** de Y pour $X = x_i$ et notée $(Y|X = x_i)$.

Couleur des yeux	Sexe		Total
	F	M	
Bleux	2	2	4
Noirs	1	5	6
Total	3	7	10

Indépendance : définition

Définition

X et Y sont **indépendantes** si

$$f_{i,j} = f_{i,\cdot}\, f_{\cdot,j} \qquad \forall (i,j) \in \{1,\dots,l\} \times \{1,\dots,r\}.$$

En multipliant par N :

$$\frac{n_{i,j}}{N} = \frac{n_{i,\cdot}}{N} \cdot \frac{n_{\cdot,j}}{N} \quad \Longrightarrow \quad n_{i,j} = \frac{n_{i,\cdot}\, n_{\cdot,j}}{N}.$$

Interprétation

La variable X n'influence pas Y (et réciproquement).

Distance du χ^2

Définition

Effectifs théoriques :

$$T_{i,j} := \frac{n_{i,\cdot} \cdot n_{\cdot,j}}{N}.$$

Distance du χ^2

$$\chi^2 = \sum_{i=1}^{l} \sum_{j=1}^{r} \frac{\left(n_{i,j} - T_{i,j}\right)^2}{T_{i,j}}.$$

Proposition

Sous l'hypothèse d'indépendance, la quantité χ^2 suit la loi χ^2 de dégré de liberté (ddl) égale à $(l-1) \times (r-1)$, on note $\chi^2 \sim \chi^2((l-1)(r-1))$

Exemple

Le tableau des effectifs théoriques de l'exemple précédent est donné comme suit :

Couleur des yeux	**Sexe**	
	F	**M**
Bleux	$\frac{4\times 3}{10} = 1.2$	2.8
Noirs	1.8	4.8

La quantité χ^2 observée est donnée par :

$$\chi^2 = \frac{(2-1.2)^2}{1.2} + \frac{(2-2.8)^2}{2.8} + \frac{(1-1.8)^2}{1.8} + \frac{(5-4.2)^2}{4.2} = 1.268$$

Règle de décision

Afin de décider si les variables X et Y sont indépendantes ou non, on doit comparer la valeur calculée χ^2 à celle tabulée (lue depuis la table statistique de la loi de $\chi^2_\alpha(ddl)$). On accepte l'indépendance si la valeur observée est inférieur à celle tabulée, i.e $\chi^2 < \chi^2_\alpha(n)$.

Table – Extrait de la table de χ^2

ddl	$\chi^2_{0.995}$	$\chi^2_{0.99}$	$\chi^2_{0.95}$	$\chi^2_{0.1}$	$\chi^2_{0.05}$	$\chi^2_{0.005}$
1	0.0000	0.0002	0.0039	2.7055	3.8415	7.8794
2	0.0100	0.0201	0.1026	4.6052	5.9915	10.5966
3	0.0717	0.1148	0.3518	6.2514	7.8147	12.8382
4	0.2070	0.2971	0.7107	7.7794	9.4877	14.8603

Ici, on $\chi^2 = 1.268 < \chi^2_{0.05}(1) = 3.8415$, on dit qu'au seuil $\alpha = 5\%$, on ne peut pas rejeter l'hypothèse d'indépendance entre X et Y. X et Y sont indépendantes.

Exercice

Énoncé. Une e-commerce analyse 100 clients selon :

- X : tranche d'âge (18-25, 26-40, 41+),
- Y : canal d'achat préféré (mobile, ordinateur, magasin).

$Y \backslash X$	Mobile	Ordinateur	Magasin	$n_{i,\cdot}$
18–25	20	5	5	30
26–40	10	15	10	35
41+	5	10	20	35
$n_{\cdot,j}$	35	30	35	$N = 100$

Question : Au seuil $\alpha = 5\%$, l'âge et le canal d'achat sont-ils indépendants ? $\Rightarrow$ On calcule les effectifs théoriques $T_{i,j} = n_{i,\cdot} n_{\cdot,j}/N$, puis χ^2 et la comparer à celle tabulée.

Calculs de l'exercice

Effectifs théoriques sous H_0 :

	Mobile	Ordinateur	Magasin
18–25	10,5	9	10,5
26–40	12,25	10,5	12,25
41+	12,25	10,5	12,25

Calcul de χ^2 :

$$\chi^2 \approx \frac{(20-10{,}5)^2}{10{,}5} + \cdots + \frac{(20-12{,}25)^2}{12{,}25} \approx 25.226$$

$$\chi^2_{0.05}(4) = 9.4877,$$

Conclusion : $\chi^2 = 22.45 > \chi^2_{0.05}(4) = 9.4877 \Rightarrow$ dépendance entre l'âge et le canal d'achat.

Exemple appliqué : campagne marketing régionale

Contexte. Une entreprise lance une campagne publicitaire. Elle interroge 155 clients sur leur *région* X et le fait qu'ils aient *vu la publicité* Y.

Région	Oui	Non	$n_{i,\cdot}$
Île-de-France	25	10	35
Auvergne-Rhône-Alpes	18	12	30
Nouvelle-Aquitaine	10	15	25
Occitanie	8	17	25
Hauts-de-France	15	25	40
$n_{\cdot,j}$	76	79	$N = 155$

Question : la perception de la campagne dépend-elle de la région ? (On prendra $\alpha = 5\%$).

Covariance

Définition

$$\mathrm{Cov}(X, Y) = \frac{1}{N} \sum_{i=1}^{l} \sum_{j=1}^{r} n_{i,j} \, (x_i - \overline{X})(y_j - \overline{Y}) = \frac{1}{N} \sum_{i,j} n_{i,j} \, x_i y_j - \overline{X} \, \overline{Y},$$

avec $\overline{X} = \frac{1}{N} \sum_i n_{i,\cdot} \, x_i$ et $\overline{Y} = \frac{1}{N} \sum_j n_{\cdot,j} \, y_j$.

Propriétés

1. $\mathrm{Cov}(aX + b, \, Y) = a \, \mathrm{Cov}(X, Y)$.
2. $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$.
3. Si X et Y sont indépendantes, $\mathrm{Cov}(X, Y) = 0$.

Coefficient de corrélation linéaire

Définition

$$\mathrm{Cor}(X, Y) = \frac{\mathrm{Cov}(X, Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}.$$

Propriétés

1. $\mathrm{Cor}(X, Y) \in [-1, 1]$.
2. $\mathrm{Cor}(X, X) = 1$, $\mathrm{Cor}(X, -X) = -1$.
3. Si X et Y indépendantes, $\mathrm{Cor}(X, Y) = 0$.

Interprétation

Corrélation **forte** si $|\mathrm{Cor}(X, Y)| \geq 0{,}8$. Corrélation **médiocre** si $0{,}5 < |\mathrm{Cor}(X, Y)| < 0{,}8$. **Mauvaise** corrélation si $|\mathrm{Cor}(X, Y)| \leq 0{,}5$.

Mise en garde : corrélation $\neq$ causalité

Attention

Un lien fort entraîne une forte corrélation, mais **une forte corrélation ne prouve pas une causalité**.

Exemples classiques

- Nombre de glaces vendues et nombre de noyades $\Rightarrow$ les deux augmentent en été (variable cachée : température).
- Investissement publicitaire et ventes $\Rightarrow$ corrélation positive, mais la causalité peut être inverse (les entreprises qui vendent plus investissent plus).
- Nombre de serveurs informatiques et chiffre d'affaires d'une entreprise $\Rightarrow$ liés à la taille de l'entreprise.

Exemple fil rouge : revenu et dépenses annuelles

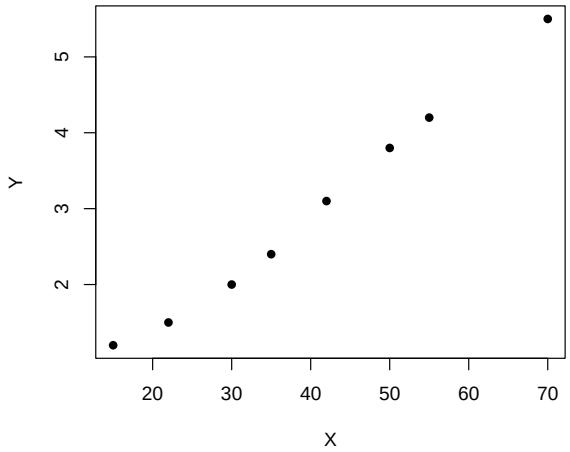
Énoncé. Une enseigne de distribution a interrogé 8 clients et a relevé :

- X : revenu annuel du client (en K€)
- Y : dépenses annuelles chez l'enseigne (en K€)

Client	1	2	3	4	5	6	7	8
X (K€)	15	22	30	35	42	50	55	70
Y (K€)	1.2	1.5	2.0	2.4	3.1	3.8	4.2	5.5

Question : peut-on dire que les dépenses dépendent du revenu ?
$\Rightarrow$ On utilise le tableau de contingence si l'on regroupe en classes.

Examen visuel



Exemple : corrélation entre revenu et dépenses

Données du fil rouge :

$$\overline{X} = 39{,}875, \quad \overline{Y} = 2{,}9625.$$

$$\mathrm{Cov}(X, Y) \approx 23{,}27, \quad \mathrm{Var}(X) \approx 287{,}85, \quad \mathrm{Var}(Y) \approx 1{,}89.$$

$$\mathrm{Cor}(X, Y) = \frac{23{,}27}{\sqrt{287{,}85 \times 1{,}89}} \approx 0{,}995.$$

Conclusion : corrélation quasi parfaite et positive $\Rightarrow$ forte relation linéaire entre revenu et dépenses.

Application économétrique

Cette corrélation justifie une régression linéaire pour prédire les dépenses futures d'un client à partir de son revenu.

Régression : principe

But

Si X et Y sont fortement corrélées, chercher une fonction f telle que $Y = f(X)$ (ou $X = f(Y)$).

- **Régression de Y en X** : on prédit Y connaissant X ; $Y = aX + b$.
- **Régression de X en Y** : on prédit X connaissant Y ; $X = a'Y + b'$.

On se limite au cas **linéaire**.

Applications

- Économie : élasticité prix-demande, fonction de consommation.
- Finance : β d'un actif (CAPM), relation rendement–risque.
- Data science : modèle linéaire (baseline), prédiction de prix, scoring.

Conditions d'application

On effectue une régression linéaire si :

1. le nuage de points semble se répartir le long d'une droite,
2. il est raisonnable d'expliquer/prédire Y par X (ou l'inverse),
3. le coefficient de corrélation vérifie

$$\mathrm{Cor}(X, Y) \in [-1;\ -0{,}7] \cup [0{,}7;\ 1].$$

Rappel

Corrélation $\geq 0{,}7$ en valeur absolue : condition nécessaire mais non suffisante pour une régression pertinente.

Méthode des moindres carrés

Régression de Y en X

Droite $D_{Y|X} : y = ax + b$ telle que

$$E(a, b) = \sum_{i=1}^{N} \big(y_i - (ax_i + b)\big)^2$$

soit minimale.

Régression de X en Y

Droite $D_{X|Y} : x = a'y + b'$ telle que

$$E(a', b') = \sum_{i=1}^{N} \big(x_i - (a'y_i + b')\big)^2$$

Exemple appliqué : prédiction du prix immobilier

Contexte. Une agence immobilière a relevé la *surface* X (m^2) et le *prix* Y (K€) de 10 appartements.

X (m^2)	20	47	21	52	45	74	87	98	54	123
Y (K€)	35	89	45	75	85	118	173	168	91	226

Résultats préliminaires :

$$\mathrm{Cor}(X, Y) \approx 0{,}98 \geq 0{,}7$$

Le nuage est allongé le long d'une droite $\Rightarrow$ régression linéaire pertinente.

Exemple : calcul de la droite de régression

Droite $D_{Y|X} : y = ax + b$

$$a = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(X)} \approx 1{,}80, \qquad b = \overline{Y} - a\overline{X} \approx -1{,}26.$$

$$\boxed{D_{Y|X} : y \approx 1{,}80\, x - 1{,}62}$$

Droite $D_{X|Y} : x = a'y + b'$

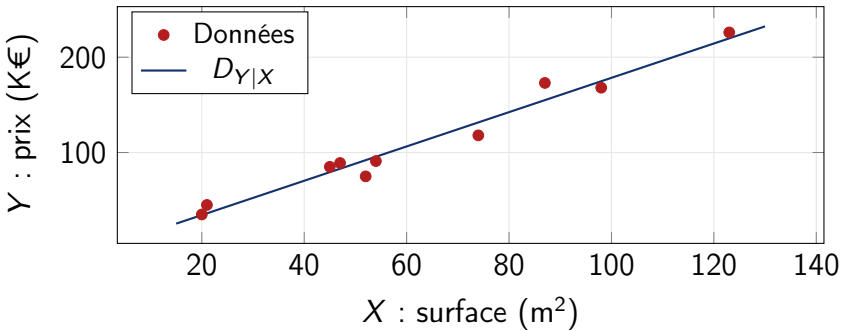
$$a' = \frac{\mathrm{Cov}(X, Y)}{\mathrm{Var}(Y)} \approx 0{,}53, \qquad b' = \overline{X} - a'\overline{Y} \approx 2{,}82.$$

$$\boxed{D_{X|Y} : x \approx 0{,}53\, y + 2{,}82}$$

Prédiction. Pour un appartement de $x^* = 60$ m^2 :

$$y^* \approx 1{,}80 \times 60 - 1{,}62 \approx 106{,}38 \text{ K€}.$$

Représentation graphique de la droite $Y|X$



Les deux droites sont proches car $|\mathrm{Cor}(X, Y)| \approx 0{,}98$ est proche de 1.

Interprétation économique

Coefficient $a \approx 1{,}80$

Chaque m^2 supplémentaire est associé à une hausse moyenne du prix d'environ 1,80 K€, soit 1 800 €.

Attention

- Il s'agit d'une association, pas nécessairement d'une causalité.
- La prédiction reste valable pour des surfaces proches de la plage observée (20–123 m^2).
- Hors de cette plage : extrapolation risquée.

Application Data Science

- Modèle de *scoring immobilier* pour estimer automatiquement un prix,
- Base pour des modèles plus riches (régression multiple, arbres, *gradient boosting*).

Références

- Rousselle, A. *Statistique bivariée*, cours IUT Dijon.
- Saporta, G. *Probabilités, analyse des données et statistique*.
- Hastie, T., Tibshirani, R., Friedman, J. *The Elements of Statistical Learning*.
- Wooldridge, J. *Introductory Econometrics*.
- Hull, J. *Options, Futures and Other Derivatives*.